

الجمهورية العربية السورية
المعهد العالي للعلوم التطبيقية والتكنولوجيا
قسم المعلومات-برمجيات وذكاء صناعي
العام الدراسي 2025-2026

مشروع السنة الرابعة

(SonicSight)

فصل المصادر السمعية-البصرية بالتعلم ذاتي الإشراف عبر تحديد
الموقع على مستوى البكسل

إعداد

جعفر محفوض

حاتم ابراهيم

إشراف

د. مصطفى دقاق

م. مرح حسن

الملخص

يعرض هذا العمل نظام SonicSight لفصل المصادر الصوتية الموجّه بصرياً في الزمن شبه الحقيقي على عتادٍ استهلاكي: يلتقط تطبيق أندرويد صورة الكاميرا وصوت الميكروفون معاً ويبيئهما إلى خادم استدلال عبر قناة gRPC ثنائية الاتجاه، فيعيد الخادم مسارين صوتيين مفصولين مع خريطة حرارية تُوضّح موضع المصدر داخل المشهد، فيُشغّل الصوت المفصول وتُرسم الخريطة فوق المعاينة الحية. ويدمج النظام نموذجين مدربين مسبقاً مختلفين معمارياً وإطارياً — Sound of Pixels لفصل الآلات الموسيقية وفق نصفي الإطار مع نمط لمسي، و Multisensory لفصل الكلام داخل الشاشة عن خارجها — خلف سجلّ مواصفات مجمّدة واحد، يقيمان معاً في عملية واحدة على بطاقة رسومات واحدة، ويجري التبدل بينهما لكل جلسة بثّ عبر بيانات وصفية على مستوى القناة.

والمشروع دراسة حالة بحثية لا منتجاً نهائياً: لم يُدرّب أيّ نموذج ولم تُجر دراسة مستخدمين، وغايته قياس جدوى هذه التقنية أساساً محتملاً لتطبيقات مساعدة قياساً أميناً. حُرّر 58 متطلباً وظيفياً و43 هدفاً غير وظيفي مصنفاً وفق ISO/IEC 25010، وكتب العتبات في ملف واحد قبل وجود منظومة القياس ثم قيست بمنظومة حمل وإجهاد مبنية على أكواد المشروع نفسها. فبلغ زمن أول نتيجة عند المئين 95 ما مقداره 6.42 ثانية لنمط النصفين و2.77 ثانية لنمط الكلام، وزمن الاستدلال للنافذة 60 و154 مللي ثانية على الترتيب، وسقف التزامن المقيس ثلاث جلسات على بطاقة GTX 1660 Ti. وكشفت الحملات خمسة عيوب مرقمة على الخادم، وعشرة على العميل بعد حملة تحقّق ضمّت 157 اختبار وحدة.

والنتيجة المركزية أن الكمون الإدراكي الحالي — نحو 1.4 إلى 3 ثوانٍ — تفرضه بنية نافذة التحليل في النموذجين لا هندسة النظام، وأنه يبعد مرتبتين إلى ثلاث مراتب عشرية عن متطلبات المساعدة السمعية الحوارية الفورية؛ فالعائق مسألة بحث نماذج لا مسألة هندسة أنظمة.

الكلمات المفتاحية: فصل المصادر الصوتية الموجّه بصرياً؛ التعلم ذاتي الإشراف؛ البث ثنائي الاتجاه؛ gRPC؛ أندرويد؛ الكمون الخوارزمي؛ ISO/IEC 25010؛ دراسة جدوى.

Abstract

This work presents SonicSight, a near-real-time, visually guided audio source separation system running on consumer hardware. An Android application captures camera frames and microphone audio together and streams them to an inference server over a bidirectional gRPC channel; the server returns two separated audio tracks and a heatmap locating the sound source in the scene, which the handset plays back and draws over the live viewfinder. Two pre-trained models of different architectures and frameworks sit behind one frozen specification registry — Sound of Pixels, separating musical instruments by the left and right halves of the frame with an additional touch mode, and Multisensory, separating on-screen from off-screen speech — both resident in a single process on a single consumer GPU.

The project is a research case study, not a finished product. Its purpose is to measure honestly how viable the technique is as a basis for assistive applications. Fifty-eight functional requirements and forty-three non-functional targets under ISO/IEC 25010 were written in verifiable form, every threshold recorded in one file before any measurement infrastructure existed, then measured. Time to first result at the 95th percentile was 6.42 s in halves mode and 2.77 s in speech mode; per-window inference was 60 ms and 154 ms; the concurrency ceiling was three sessions on a GTX 1660 Ti.

The central finding is that the present perceptual latency — roughly 1.4 to 3 seconds — is imposed by the analysis-window structure of the two models rather than by the engineering of the system, and sits two to three orders of magnitude away from the requirements of immediate conversational hearing assistance. The obstacle is a question of model research, not of systems engineering.

Keywords: visually guided source separation; self-supervised learning; bidirectional streaming; gRPC; Android; algorithmic latency; ISO/IEC 25010; feasibility study.

جدول المحتويات

V	1. أهداف المشروع.....
VI	2. المتطلبات الوظيفية وغير الوظيفية.....
VI	2.1 المتطلبات الوظيفية.....
VII	2.2 المتطلبات غير الوظيفية.....
IX	2.3 حالات الاستخدام.....
X	3. مخططات تصميم النظام.....
X	3.1 المخطط الصندوقي العام.....
XI	3.2 معمارية الخادم.....
XII	3.3 معمارية تطبيق الهاتف.....
XIII	3.4 مخطط تدفق خط المعالجة الكامل.....
XIV	3.5 مخططا نموذجي الذكاء الاصطناعي.....
XVI	3.6 مخطط تسلسل جلسة البث.....
XVII	3.7 مخطط التوقيت والكمون.....
XVIII	3.8 بنى المعطيات — وغياب قاعدة البيانات.....
XIX	4. التنفيذ والاختبارات.....
XIX	4.1 المعمارية المثبتة لكل جزء ومبرراتها.....
XX	4.2 تفصيل أجزاء النظام وطريقة تنفيذ التكامل فيما بينها.....
XXI	4.3 بسودوكود للخوارزميات المحورية.....
XXII	4.4 خطة الاختبارات ونتائجها.....
XXV	4.5 العيوب المكتشفة ومآلاتها.....
XXVI	5. نتيجة الجدوى وحدود النظام.....
XXVIII	6. الخاتمة.....
XXIX	المراجع.....
XXXII	الملحق أ — بيانات القياس المرجعية.....

1. أهداف المشروع

كُتبت أهداف الدراسة قبل المتطلبات، وصيغت المتطلبات لخدمتها. والأهداف خمسة:

الهدف الأول (O1): تشغيل خط معالجة كامل وحيّ على عتاد استهلاكي — التقاط على الهاتف، فنقل عبر الشبكة، ففصل عصبوني على الخادم، فإرجاع الصوت مع طبقة توضيح بصرية.

الهدف الثاني (O2): تشغيل نموذجين مدربين مسبقاً، مختلّفي المعمارية والإطار (PyTorch + TensorFlow)، خلف آلية اختيار واحدة وفي عملية واحدة على بطاقة رسومات واحدة [1][2][15][16].

الهدف الثالث (O3): قياس هذا الخط قياساً أميناً — أي معرفة سبب كل جزء من الكمون، وقياس الذاكرة بشروط معلنة، وبناء فحوص تفشل إذا أخطأ التوصيل بدل أن تمرّ بصمت.

الهدف الرابع (O4): تحديد المسافة بين ما يبلغه النظام اليوم وما تتطلبه المساعدة السمعية الحوارية الفورية، وتسمية العامل الذي يفرض تلك المسافة.

الهدف الخامس (O5): ترك أثر يمكن البناء عليه — عقد واحد لإضافة أي نموذج جديد، ومنصّات تحقق تعطي النتيجة نفسها كلما أعيد تشغيلها، وتوثيق يتتبع إلى سطر الكود.

وحددت خارج نطاق الدراسة صراحةً، منعاً لتضخم المتطلبات وصوناً للأمانة العلمية: لم يُجر أي تدريب أو ضبط دقيق لأي نموذج، فكلّا النموذجين نقطتا تحقق مدريّتان منشورتان بحثياً؛ ولم تُجر أي دراسة مستخدمين، ولم يستخدم النظام أي فرد من الفئة المستفيدة المفترضة؛ ولا يقدم النظام أي ادّعاء طبي أو سريري وليس جهازاً طبياً؛ والقناة الشبكية نصّ صريح على شبكة محلية موثوقة بوضعية أمنية متعمّدة ومعلنة لبيئة مخبرية؛ ولا يدّعي النظام مساعدة حوارية فورية.

2. المتطلبات الوظيفية وغير الوظيفية

2.1 المتطلبات الوظيفية

يعمل النظام لثلاثة فاعلين، وهم أنفسهم فاعلو مخطط حالات الاستخدام في القسم 2.3: المستمع، وهو حامل الهاتف الذي يبدأ الجلسة ويختار النمط ويستمع ويلمس؛ والمشغل، الذي ينشر الخادم ويهيئه ويراقبه؛ والمطور، الذي يضيف النماذج ويولد أكواد البروتوكول ويشغل منصّات التحقق. وما لا فاعل بشري له — كتسلسل أعمال المسرّع أو عزل حالة الجلسات — كُتب بصيغة «يضمن النظام» لأنه ضمانه داخلية لا خدمة يطلبها أحد.

وعلى هذا حُرر 58 مطلباً وظيفياً بصيغة قابلة للتحقق وفق ISO/IEC/IEEE 29148 [30]، موزعة على تسع فئات (الالتقاط، البث، الاستدلال وإدارة الجلسات، الفصل، التوزيع، التشغيل، اختيار النموذج، الإعداد، التشخيص)، لكل منها معرّف ثابت وألوية بمنهجية MoSCoW [38] وطريقة تحقق. ويعرض الجدول 1 مختارات تغطي الفئات كلها؛ أما حالة تنفيذ كل مطلب ونتيجة تحقيقه فمكانهما القسمان 4.4 و4.5 منعاً للتكرار، والجرد الكامل بنصوصه ومبرراته في وثيقة التحليل المرافقة داخل مجلد docs في المستودع.

المعرّف	الفاعل	المتطلب	الألوية
FR-001	المستمع	يسمح النظام للمستمع بأن يلتقط صورة الكاميرا وصوت الميكروفون معاً وفق ملف تعريف النموذج الفعّال	أساسي
FR-002	النظام	يلتقط النظام الصوت بمعدل 44100 هرتز المضمون على أندرويد، ثم يخفضه داخل التطبيق بمرشّح FIR ذي 121 معاملاً إلى معدل السلك (11025 أو 22050 هرتز)	أساسي
FR-004	النظام	يضبّط النظام إيقاع الإطارات وفق الملف الفعّال (8 أو 30 إطاراً/ثانية) ويُسقط الأقدم تحت الضغط الارتدادي	أساسي
FR-006	المستمع	يسمح النظام للمستمع بأن يربط الالتقاط بالجلسة، فيتوقف عند مغادرة الواجهة الأمامية	أساسي
FR-010	النظام	ينقل النظام المعطيات في الاتجاهين على قناة gRPC واحدة لكل جلسة، برسائل StreamChunk وStreamResult	أساسي
FR-011	النظام	يطبّق النظام سياسة فقدٍ لكل وسيط: الصوت دون فقد (كتل 125 مللي ثانية)، والإطارات قابلة للإسقاط	أساسي
FR-012	المستمع	يسمح النظام للمستمع بأن يسمّي النموذج في البيانات الوصفية sonicsight-model عند فتح القناة، ويقع على نموذج افتراضي عند غيابها	أساسي
FR-013	النظام	ينهي النظام الجلسة إنهاءً صريحاً بعلم is_last، مع دفع ذيل التراكب والجمع قبل الإغلاق	أساسي
FR-020	النظام	يعزل النظام حالة كل جلسة (عوازل الصوت والإطارات والتراكب واللمس) عن بقية الجلسات	أساسي
FR-021	النظام	ينتخب النظام أحدث إطار تكتمل حوله نافذة صوت كاملة، بمحاذاة قفزة STFT وبحدٍّ أدنى للتقدّم	أساسي
FR-023	النظام	يسلسل النظام كل أعمال المسرّع عبر قفل واحد على مستوى العملية	أساسي
FR-024	المشغل	يسمح النظام للمشغل بأن يشغل الخادم ولو فشل تحميل محرك منفرد، فيقدّم ما تحمّل من النماذج	أساسي

FR-030	المستمع	يسمح النظام للمستمع بأن يسمع مسارين مستقلين (يسار/يمين) بمعدل 11025 هرتز في نمط النصفين	أساسي
FR-031	المستمع	يسمح النظام للمستمع بأن يسمع مساري الكلام (داخل الشاشة/خارجها) بمعدل سلك 22050 هرتز مع إعادة تحصيل داخلية بنسبة 21:20	أساسي
FR-032	النظام	يعيد النظام بناء الصوت بلا فجوات ولا تكرار، بتراكب وجمع وتلاشي متقاطع وعدادات مراقبة	أساسي
FR-036	المستمع	يسمح النظام للمستمع بأن يتلقى صمناً أميناً في النمط اللمسي: طاقة صغرية للمناطق دون العتبة بدل تسريب مُصطنع	أساسي
FR-042	المستمع	يسمح النظام للمستمع بأن يرى خريطة الكلام محجوبةً حين تقل النسبة الموجبة عن 0.10، مع إعلان قيمة الثقة	أساسي
FR-043	المستمع	يسمح النظام للمستمع بأن يستعلم عن خريطة طاقة اللمس بدقة الشبكة الأصلية 14x14 وبأبعاد صريحة، دون رفع دقة زائف	أساسي
FR-045	المستمع	يسمح النظام للمستمع بأن يرى الخرائط مسجلة على المعاينة الحية بعكس تحويل الاقتصاص والتأطير	أساسي
FR-051/050	المستمع	يسمح النظام للمستمع بأن يسمع تشغيلاً مزدوج المسار على قناتي AudioTrack خلف عازل ارتجاج متكيف (من 200 إلى 500 ملي ثانية ضمن حلقة 1500)	أساسي
FR-066/060	المطور	يسمح النظام للمطور بأن يضيف نموذجاً عبر سجل مواصفات مجمدة، ويمنع كشف ثوابت النماذج كإعدادات قابلة للضبط	أساسي
FR-063/062	المستمع	يسمح النظام للمستمع بأن يبدل النموذج أثناء الجلسة بإلغاء القناة وإعادة فتحها (مهلة استقرار 700 ملي ثانية)، مع إسقاط النتائج المتقدمة بمطابقة صدى معزف النموذج	أساسي
FR-073	المشغل	يسمح النظام للمشغل بأن يعتمد قيمة افتراضية 512 ميغابايت لسقف مساحة عمل cuDNN	أساسي
FR-082/080	المشغل	يسمح النظام للمشغل بأن يفحص الجاهزية فيعلن النماذج المحملة، وأن يتلقى تشخيصات دورية تعلم الدورات فوق 140 ملي ثانية	أساسي
FR-083	المستمع	يسمح النظام للمستمع بأن يحفظ الوسائط الملتقطة على الجهاز خلف مفتاح صريح افتراضية الإيقاف	أساسي

الجدول 1: مختارات ممثلة من المتطلبات الوظيفية الـ 58 — الفاعل والصياغة والأولوية.

وإتماماً لأمانة النطاق، وُثِّقت ثمانى فجوات منتج (FR-P01 → FR-P08) يتطلبها منتج حقيقي ولا تقدّمها دراسة الحالة عمداً، أبرزها: أمن النقل والاستيثاق (TLS)، والتعافي الرشيق من رفض الأذونات، والعمل دون خادم أو دون اتصال، وسياسة دورة الحياة في الخلفية، وضوابط الموافقة والاحتفاظ بالوسائط، والمطابقة لمعيار وصولية مسمّى، وقنوات التوزيع والتحديث، وخدمة متعددة المستخدمين.

2.2 المتطلبات غير الوظيفية

صُنِّفت المتطلبات غير الوظيفية — 43 هدفاً — وفق خصائص الجودة في المعيار ISO/IEC 25010 [29] (كفاءة الأداء، الموثوقية، الملاءمة الوظيفية، التوافق، قابلية التفاعل، الأمن، قابلية الصيانة، المرونة). وطُبّق مبدآن منهجيان صارمان: أولاً، كل عتبة معرفة مرة واحدة في ملف nfr_targets.yaml بوصفه مصدر الحقيقة الوحيد الذي تقرأ منه تأكيدات منظومة الاختبار وجداول هذا التقرير معاً، فلا يمكن أن يفترق الرقم المكتوب عن الرقم المُختبر. وثانياً، كُتبت الأهداف قبل وجود منظومة القياس بتاريخ موثّق (8 آب 2026) ثم قيسَت، وحين خالف قياسُ هدفه عُُدِّل الهدف علناً مع سبب مسجّل — لا الاختبار.

ويعرض الجدول 2 الأهداف وحدها؛ أما القيم المقيسة وأحكام النجاح والإخفاق فمكانها القسم 4.4 منعاً للتكرار. ومنعاً لأي لبس في اتجاه النص داخل الخلايا العددية، كُتبت قيم عمود الهدف بالاصطلاح اللاتيني: s = ثانية، ms = مللي ثانية، وMiB = مبي بايت (ثنائية)، والمئينات p95/p99 بدل م95/99.

المعرّف	المتطلب	الهدف
NFR-PERF-001	زمن أول نتيجة، نمط النصفين (مئين 95)	$8.0 s \geq$
NFR-PERF-002	زمن أول نتيجة، نمط الكلام (مئين 95)	$3.5 s \geq$
NFR-PERF-003	انحراف إيقاع النتائج عن 125 مللي ثانية، النصفان (مئين 95)	$62.5 ms \geq$
NFR-PERF-015	انحراف الإيقاع عن 250 مللي ثانية، الكلام (مئين 95)	$62.5 ms \geq$
NFR-PERF-004	زمن الاستدلال للنافذة، النصفان	$p95 \leq 140 \cdot p99 \leq 250 \cdot \max \leq 1500 ms$
NFR-PERF-005	زمن الاستدلال للنافذة، الكلام	الحدود نفسها
NFR-PERF-006	تأخر حلقة أحداث asyncio	$p99 \leq 50 ms$
NFR-PERF-007	أرضية السعة المتزامنة، النصفان	جلستان ملتزمتان
NFR-PERF-016	أرضية السعة، الكلام	جلسة ملتزمة واحدة
NFR-PERF-008	زمن ذهاب وإياب استعلام اللمس (مئين 95)	$250 ms \geq$
NFR-PERF-011	ميل نمو ذاكرة العملية في الثبات المديد	$1.0 MiB/min \geq$
NFR-PERF-012	استقرار ذاكرة GPU في الثبات المديد	$128 MiB \geq$ (مُصالح من 64)
NFR-PERF-013	استمرارية التسلسل (فجوات النتائج)	0
NFR-PERF-014	التعافي من الاندفاع (spike)	نجاة كل الجلسات
NFR-REL-001	احتواء المدخلات المشوّهة	احتواء دون إسقاط الجلسات السليمة
NFR-REL-002	تنظيف الانقطاع المفاجئ	توازن فتح/إغلاق = 0
NFR-REL-003	رفض الرسائل المتضخمة	رفض عند النقل دون أذى
NFR-REL-004	سلوك معرّف للوسائط المنحلّة	7 حالات معرّفة
NFR-REL-005	ثبات مديد بلا أعطال	0 استثناء غير معالج
NFR-REL-006	تبديل النماذج المتكرر عبر الإطارين	صدى صحيح واستقرار موارد
NFR-FUNC-001	سلامة الفصل بإعادة تشغيل حتمية (داخل نطاق النموذج)	ارتباط بيرسون بين القناتين منخفض
NFR-FUNC-004	عقد نتائج نمط الكلام	التزام كامل
NFR-SEC-001	حصص التعرض الشبكي بالشبكة المحلية	0 وجهة خارج الشبكة المحلية
NFR-MAINT-001	نظافة جامع اختبارات الوحدة	0 خطأ جمع
NFR-MAINT-004	مصدر وحيد للعبّات (ملف YAML)	لا عتبات حرفية في كود الحمل


الجدول 2: المتطلبات غير الوظيفية وأهدافها المعلنة قبل القياس — النتائج في القسم 4.4.

وتبقى بنودٌ خارج نطاق القياس الحالي بتصريح كامل: أهداف مصفوفة أجهزة الهاتف (NFR-INT-001..004, NFR-FLEX-002/003) مرهونة بمرحلة تحقق الهاتف اللاحقة؛ وهامش التحقق المتقاطع

للتوضيح (NFR-FUNC-002) يُفحص بروتوكول قياس منفصل خارج منظومة الحمل وتعلن المنظومة عدم قياسه بأمانة؛ وهدف ذاكرة البيئة الثانوية (NFR-PERF-009) عمل متبقي عليها. كما غاب عمداً متطلب كمونٍ حواريٍّ فوري: فرضُ عتبةٍ يستحيل بلوغها بنافذتي النموذجين كان سيُنتج إخفاقاً دائماً بلا معلومة؛ والمسافة إلى ذلك المطلب هي موضوع القسم 5 بوصفها نتيجة الدراسة لا متطلباً عليها.

2.3 حالات الاستخدام

اشتُقت 25 حالة استخدام مما يفعله البرنامج فعلاً عند الرؤوس المؤتقة للمستودعات، لا من الطموح، وذلك لثلاثة فاعلين بشريين: **المستمع** (حامل الهاتف: يبدأ الجلسات ويختار الأنماط ويستمع ويلمس)، و**المشغل** (ينشر الخادم ويهيئته ويراقبه)، و**المطور** (يشغل منصّات التحقق والاختبارات ويولد أكواد البروتوكول ويضيف النماذج) — إذ إن نموذج حالات لا يضم سوى المستخدم النهائي كان سينكر نصف ما يفعله النظام. تحمل كل حالة حالة تنفيذها الصادقة، ومنها حالة مصممة غير منفذة معلمة بخط متقطع في الشكل 1[32]؛




Solid = implemented (validation status per Table 6.1 of the analysis study) · dashed = designed, not implemented.

الشكل 1: مخطط حالات الاستخدام — الفاعلون الثلاثة وحدود النظام؛ المتصل منفذ والمتقطع مصمم غير منفذ.

3. مخططات تصميم النظام

يجمع هذا الفصل المخططات الهندسية للنظام كما نُفذ فعلاً، مرسومةً من الكود لا من النوايا. تُبقي المخططات مسمّيات المكونات التقنية بالإنجليزية كما ترد في الكود حفاظاً على قابلية التتبع، وتشرح النصوص العربية المرافقة كلّ شكل. والنسخ عالية الدقة من الأشكال كلها مرفقة في مجلد docs/figures داخل المستودع.


3.1 المخطط الصندوقي العام



الشكل 2: المخطط الصندوقي للنظام — الهاتف والخادم والفاعلون وحدود الثقة الشبكية.

يتوزع النظام على طرفين يفصل بينهما حد ثقة شبكي صريح: هاتف أندرويد يلتقط ويشقّ ويعرض، وخادم يستدل ويفصل. يعبر الوصلة اللاسلكية المحلية اتجاهاً: صاعداً يحمل رسائل StreamChunk — إطارات مضغوطة بترميز JPEG مع كتل الصوت الخطية — ونازلاً يحمل رسائل StreamResult بمسارين مفصولين وخريطة توضيح. يستضيف الخادم النموذجين معاً في عملية واحدة تتقاسم قفلَ مسرّعٍ واحداً — وهو القرار المعماري D4 المعلن في القسم 4.1 — وتبقى نقاط التحقق المدربة على القرص خارج المستودعات لضخامتها، ويشير ملف README إلى مصادرها الأصلية [19][21].


3.2 معمارية الخادم



الشكل 3: طبقات الخادم — ما يُنشأ لكل جلسة (الإطار الأزرق) وما يُنشأ مرة واحدة للعملية (الإطار الكهرماني).

التمييز الحاكم في هذا الشكل ليس بين الوحدات بل بين **عمري الكائنات**: فكل قناة مفتوحة تحصل على طقمها الخاص من الحالة (عازل بث بحلقة صوت سعتها 15 ثانية وحلقة إطارات، وعوازل تراكب وجمع، وذاكرة نوافذ اللمس، وحالة العناقيد)، بينما تُحمّل الشبكات العصبونية وجلسة TensorFlow وسجلّ المواصفات مرة واحدة عند الإقلاع وتبقى مقيمة تتشاركها الجلسات كلها عبر قفل `asyncio` وحيد يُسلسل دخول المسرّع. هذا العزل هو ما يجعل جلسيتين بنموذجين مختلفين لا تتصادمان (FR-020)، وتحمّل فشل تحميل محرّك منفرد (FR-024) هو ما يتيح تشغيل الخادم على مضيف بلا TensorFlow فيقدّم النماذج المتاحة وحدها ويعلنها عبر فحص الجاهزية [15][16].


3.3 معمارية تطبيق الهاتف



الشكل 4: طبقات تطبيق أندرويد وفق نمط MVVM مع طبقة مستودع، وتدفع Kotlin Flow بينها.

يعتمد التطبيق نمط MVVM بطبقة مستودع: تمسك MainViewModel دورة حياة القناة واختيار الملف التعريفي ومرشح النتائج المتقدمة وتوزيع النتائج، ويغلف GrpcVideoRepository تفاصيل النقل: إبقاء القناة حيّة كل 30 ثانية، وسقف رسالة 16 ميغابايت، والتبديل بإلغاء القناة وإعادة فتحها. ويطبّق باعث الكتل سياسة الفقد لكل وسيط: الصوت دون فقد والإطارات بإبقاء الأحدث فقط تحت الضغط الارتدادي. وتحت ذلك تجلس مصادر المنصة: CameraX للالتقاط بملفّين (8 أو 30 إطاراً/ثانية)، وAudioRecord بمعدل 44100 هرتز يُخفّض داخلياً، وقناتا AudioTrack للتشغيل الموزّع يميناً ويساراً خلف عازل ارتجاج متكيف. ومبرّرات اختيار هذا النمط في القرار D8 بالقسم 4.1[23][24][25].


3.4 مخطط تدفق خط المعالجة الكامل



الشكل 5: التدفق الكامل من التسجيل إلى المعالجة المسبقة فاليث فالاستدلال فاليث العائد فالتشغيل — نمط النصفين، بالأبعاد والمعدلات الفعلية.

يتتبع الشكل نافذة واحدة من الفوتون وموجة الضغط حتى الصوت المسموع. على الهاتف: تُخنق إطارات الكاميرا (1280×720) إلى 8 في الثانية، فتُدار وتُشطر نصفين يُقَصَّ كلُّ منهما إلى 224×224 ويُضغَط بترميز JPEG بجودة 90؛ ويُقرأ الميكروفون كتلاً من 5512 عيّنة (125 ملي ثانية) تُرَشَّح وتُخَفَّض إلى 1378 عيّنة بمعدل 11025 هرتز [12]. وعلى الخادم لكل قفزة: تُنتخب نافذة 65536 عيّنة (5.944 ثانية) بمحاذاة قفزة التحويل، فتحويل STFT 1022/256 إلى طيف 256×512، فلفٌ لوغاريتمي ترددي إلى 256×256 تلتهمه شبكة U-Net، بينما تمر ستهُ إطارات في ResNet-18 الموسَّعة لتخرج متجهات بصرية؛ يمزجها المُرْكَب الخطي أقنعةً تُفَكَّ وتُطبَّق على الطيف بطور المزيغ ثم بالتحويل العكسي، فشريحة مركزية تُخاط بالتراكب والجمع. وفي النازل: نحو 8 نتائج في الثانية تدخل عازل الارتجاج فالتشغيل، وتُرسم الخريطة (56×56) فوق المعاينة. ويضيف النمط اللمسي مساراً رخيصاً: استعلام يُجاب من ذاكرة النافذة المخبَّاة دون أي تمرير أمامي جديد [10][12][22].


3.5 مخطط نموذجي الذكاء الاصطناعي



Self-supervised (Mix-and-Separate) on MUSIC — 11 musical-instrument classes. $K = 32$ in the deployed checkpoint.

الشكل 6: معمارية Sound of Pixels كما نُشرت وكما نُشر التحقق منها — بقيم النشر الفعلي ($K = 32$).

ثلاث شبكات: شبكة فيديو [1] — ResNet-18 موسّعة بخطوة 16 — تُنتج متجهاً بصرياً من 32 مركبة لكل خلية مكانية، وشبكة صوت — U-Net بسبع طبقات نزولاً وسبع صعوداً — تُنتج 32 خريطة سمات طيفية، ومركّب خطي بـ 33 معاملاً فقط يضريهما ويُخرج قناع الفصل. خطية المركّب هي الخاصية الحاسمة تطبيقياً: الشبكتان الغاليتان تعملان مرةً واحدة لكل نافذة، وبعدها يكون قناع أي خلية — أو أي منطقة ملموسة — جمعاً موزوناً رخيصاً، وهو ما يقوم عليه النمط اللمسي بأكمله. دُرّب النموذج ذاتيّ الإشراف بأسلوب المزج والفصل [1] على 685 مقطع عزف منفرد وثنائي لإحدى عشرة آلة موسيقية، ولذلك مجاله الآلات الموسيقية تحديداً [5][6][7].




Pretext task: audio-video temporal alignment, self-supervised on ~750 k AudioSet clips. Locked: vid_dur → 2.102 s true window; hop 250 ms.

الشكل 7: معمارية Multisensory — جذع اندماج مبكر برأسين: توزيع بخريطة تفعيل الصنف، وفصل كلام داخل/خارج الشاشة.

يدمج هذا النموذج الفيديو والموجة الصوتية الخام مبكراً في جذع ثلاثي الأبعاد دُرّب ذاتيّ الإشراف على مهمة ذريعة — هل هذا الصوت متزامن مع هذا الفيديو؟ — على نحو 750 ألف مقطع من AudioSet. يتفرع عنه رأسان: رأسٌ محاذاة تُشتق من لوغته خريطة تفعيل صنف بدقة 7x7 تُجيب «أي رقعة من الصورة تفسّر الصوت؟»، ورأسٌ فصلٍ بأقنعة طيفية ضُبط على VoxCeleb فمجاله الكلام [4]. وتفرض المهمة الذريعة قيوداً دلاليّاً مهماً حوّل إلى متطلب: خريطة سالبة الأغلب جوابٌ ذو معنى («الصوت لا يطابق الصورة») لا ضجيجاً، ولذلك تحجب بوابة الثقة الخريطة حين تقل نسبتها الموجبة عن 0.10 (FR-042) بدل رسم غطاء مضلل [2][3][4][8].


3.6 مخطط تسلسل جلسة البث



الشكل 8: تسلسل الجلسة — الفتح بالبيانات الوصفية، طور الملء، الحالة المستقرة، التبديل، فالإنهاء الصريح.

تُفتح القناة ببيانات وصفية تسمي النموذج فيُحلل إلى مواصفة مجمدة وتُنشأ حالة الجلسة؛ وخلال ملء النافذة الأولى تصل نتائج معلمة is_buffering تُغذي واجهة انتظار صادقة. في الحالة المستقرة تتكرر دورة استدلال كل قفزة، وكل نتيجة تحمل رقم تسلسل وصدي معرف النموذج وحقول توقيت الخادم — وهي الحقول ذاتها التي قاست بها منظومة الحمل الخادم عبر بروتوكوله السليكي نفسه. والتبديل إلغاء وإعادة فتح لا غير، لأن ملفي الالتقاط متنافران (8 إطارات/11025 هرتز مقابل ≈30 إطاراً/22050 هرتز)، ويُسقط العمل أي نتيجة يخالف صداها الاختيار الحالي. وينتهي كل شيء بعلم is_last فدقي ذيل التراكب والجمع بإغلاق نظيف — وقد قيس توازن الفتح والإغلاق صفراً على 67 فتحة بينها 50 انقطاعاً مفاجئاً [19][20].


3.7 مخطط التوقيت والكمون



الشكل 9: النافذة المنزلقة والقفزة وتفكيك الكمون إلى خوارزمي وحوسي — أهم شكل لفهم سلوك النظام.

يفصل هذا الشكل كميتين يخلطهما كثيرون: **الكمون الخوارزمي** الذي تفرضه بنية النموذج (نصف نافذةً متوسطاً: ≈2.97 ثانية للنصفين و≈1.05 ثانية للكلام) ولا يعالج إلا بتغيير النموذج ذاته، و**كمون المعالجة** الذي تفرضه الحوسبة والتسليم (استدلال بمئين 95 قدره 60 ملي ثانية، ثم شبكة وعازل ارتجاج). ولأن الأول يبتلع الثاني بمرتين عشريتين، فإن تسريع الاستدلال لن يغير التجربة المحسوسة — وهذه هي الحقيقة التي تؤسس نتيجة الجدوى في القسم 5. لاحظ أيضاً أن كل نتيجة شريحة مركزية بطول القفزة فقط، فتتراكب النوافذ المتعاقبة تراكباً كثيفاً يمنح الخياطة نعومتها [9][10].

3.8 بنى المعطيات — وغياب قاعدة البيانات



No relational database exists by design: the pipeline is stateless across sessions, media is never persisted server-side, and every structure above is in-process memory, sized and bounded per the model specification.

الشكل 10: بنى المعطيات المقيمة في الذاكرة لكل جلسة وعلاقتها — البديل الصادق عن مخطط ERD.

لا يحوي النظام قاعدة بيانات علائقية، ولذلك لا يوجد مخطط كيانات وعلاقات — ERD — لأنه لا كيانات مخزنة أصلاً، وهذا قرار تصميمي معلّل لا نقصاً: فالخط عديم الحالة عبر الجلسات، ولا تُحفظ أي وسائط على الخادم إطلاقاً — وأي حفظ تشخيصي يقبع خلف مفتاح صريح افتراضيّ الإيقاف (FR-081/083) — وهو ما يخدم خصوصية من تلتقطهم الكاميرا والميكروفون. يعرض الشكل 10 بدل ذلك البنى الحية المحدودة السعة: حالة الجلسة المشتقة من المواصفة المجمّدة، وعازل البث بحلقته، وعوازل التراكب والجمع بعدّاداتها، وذاكرة نوافذ اللمس (ثلاث نوافذ بسعة 9.46 ميغابايت للنافذة تُستثنى منها النافذة المجمّدة من الإخلاء)، وحالة العناقيد بثبات هوياتها عبر النوافذ.

4. التنفيذ والاختبارات

4.1 المعمارية المتبعة لكل جزء ومبرراتها

لكل جزء من النظام معمارية معلنة ومبررة: الخادم طبقات من سطح الخدمة حتى الأوزان (الشكل 3) بنمط سجل-ومحركات: كل نموذج مواصفة مجمدة ModelSpec تحمل كل ثابت يعتمد عليه شكل القناة (نافذة، قفزة، معدلات، قاعدة إطارات، اصطلاح خريطة) ومصنع محرك كسول، بينما تسلسل كل أعمال المسرع عبر قفل واحد. وتطبيق الهاتف بنمط MVVM بمستودع (الشكل 4) يعزل النقل عن العرض ويجعل قلب المنطق قابلاً لاختبار الوحدة. ومستودع multisensory نسخة مضمّنة من كود البحث المنشور رُحلت من بايثون 2 إلى 3 وتعمل عبر طبقة توافق الإصدار الأول داخل TensorFlow 2.21، مع رقع محدودة موثقة: مسبار خريطة التفعيل، وجلسة قابلة للتهيئة، وسقف مساحة cuDNN، واستيرادات كسولة تمنع جرّ حزم الرسم إلى الخادم [37].

أُخذت القرارات المعمارية الثمانية الكبرى قراراتٍ موثقة (ADR-0001..0008, docs/adr)، لكلٍ منها بدائل دُرست وكلفةٌ مصرّح بها — فالتعليل الذي لا يذكر أثمانه دعائيةٌ لا هندسة:

القرار	المُختار	أبرز البدائل المدروسة	المبرر والتمن
D1	استدلال خادم-عميل لا على الجهاز	تشغيل على الهاتف (تحويل النماذج وضغطها)	حجم النموذجين وإطاراهما المزدوجان وذاكرة المسرع المطلوبة تتجاوز هواتف الفئة المستهدفة؛ الثمن المقبول: تبعية شبكية وأرضية كمون وتعزّض خصوصية داخل الشبكة المحلية
D2	بث gRPC ثنائي الاتجاه	استطلاع دوري عبر REST؛ أو مقابس WebSocket؛ أو نقل وسائط RTP	قناة واحدة مستمرة بالاتجاهين مع ترقيم وضغط ومهل مدمجة؛ الاستطلاع يضيف كموناً وضجيجاً، ونقل الوسائط المنفصل يعقد التزامن مع رسائل التحكم
D3	JSON لا Protocol Buffers	JSON/Base64	حمولات ثنائية كثيفة — JPEG/PCM — يجعل ترميزها النصي مكلفاً حجماً ومعالجة؛ والعقد الصارم يؤدّ أكواد الطرفين من ملف واحد
D4	عملية واحدة تستضيف الإطارين	خدمتان منفصلتان (PyTorch + TensorFlow)	سياق CUDA ونوى التسريع يكلفان نحو 1.3-1 غيغابايت لكل عملية؛ والفصل يدفع الثمن مرتين ويُفشل بطاقة 6 غيغابايت — والقياس النهائي: النماذج الثلاثة مقيمة بـ 894 مبي بايت فقط
D5	سجل مواصفات + محركات لا تفريعات شرطية	تفريع شرطي لكل نموذج داخل الخادم	كل فرق بين النماذج يسكن مواصفة مجمدة واحدة؛ إضافة نموذج = إدخال سجلي، ومورس ذلك فعلاً مرتين أثناء المشروع
D6	نافذة منزلة بتراكب وجمع	استدلال كتل مستقلة متجاورة	الكتل المستقلة تُنتج وصلات مسموعة وتمنع أي سياق زمني؛ الثمن: كمون خوارزمي بنصف نافذة — وهو المقيد الحاكم المعلن في القسم 5
D7	تبديل يختاره المستخدم لا دمج آلي	دمج/بؤابة بين النموذجين آلياً	مجالا النموذجين مختلفان (آلات موسيقية مقابل كلام) ودلالاتا مخرجيهما مختلفتان؛ الدمج يمؤه الدلالة ويضاعف الكلفة — وقد أزيل مسار دمج سابق بالكامل

القرار	المُختار	أبرز البدائل المدروسة	المبرر والتمن
D8	MVVM بمستودع على الهاتف	منطق داخل ال Activity مباشرة	فصل دورة حياة القناة عن الواجهة يجعل التبديل والتعافي قابلين للاختبار، وتدفق Kotlin Flow يطابق طبيعة النتائج الانسيابية

الجدول 3: القرارات المعمارية الثمانية — ملخص سجلات ADR.

ويكمل الصورة صنف من الثوابت **المقفلة عمداً**: قيم أثبت هذا المشروع بالتجربة أن الانحراف عنها يُنتج خرجاً واثق المظهر خاطئ المضمون، فجُمِّدت في الكود وحُظر كشفها كإعدادات — المتطلب FR-066:

الثابت	القيمة المقفلة	الدليل التجريبي على القفل
نافذة الكلام	44144 عينة بمعدل 21000 هرتز، أي 2.102 ث فعلياً؛ والمعامل المقفل vid_dur = 2.135 قبل التقريب الطيفي	مضاعفة النافذة قلبت فحص القناع الحاسم من نجاح (0.8248+) إلى إخفاق واثق المظهر (0.0924+) على المقطع ذاته
دقة خريطة الكلام	7×7 لا النمط عالي الدقة 14×14	ارتباط النسختين $r = 0.0684$ — لا علاقة بينهما عملياً؛ والعالية أبطأ
قفزة الكلام	250 ميلي ثانية	استدلال يقارب 143–154 مث لا يلاحق قفزة 125؛ والتأخر يتراكم بلا حد
سقف مساحة cuDNN	512 ميغابايت افتراضياً	بلا سقف يحتجز المخصص 2884 مبي بايت لعبء يقارب 0.5 غيغابايت؛ والسقف لا يكلف زمناً مقيساً (147.3 مقابل 147.8 مث)
صوتيات Sound of Pixels	11025 هرتز، نافذة تحويل بطول 1022 وقفزة 256، طول K = 32، 65536 عينة	قيم مرتبطة بنقطة التحقق المدروسة؛ أي تغيير يعمل بلا خطأ ويُخرج هراء — ولذلك يحظر FR-066 كشفها كإعدادات

الجدول 4: الثوابت المقفلة والدليل القياسي وراء كل قفل.

4.2 تفصيل أجزاء النظام وطريقة تنفيذ التكامل فيما بينها

عقد التكامل الوحيد بين الطرفين ملفً sonicsight.proto واحد، تحتفظ به كلتا الشيفرتين نسخة مطابقة بايتاً ببايت ويُتحقق من تطابقها آلياً — NFR-COMPAT-001 — وتُولد منه أكواد بايثون على الخادم و Kotlin على الهاتف؛ فأَي تعديل تعاقدي يمرّ من الملفين معاً في التزامٍ واحد ثم بإعادة توليدٍ على الجانبين (UC-21). ويجري اختيار النموذج تكاملياً عبر مفتاح البيانات الوصفية sonicsight-model عند فتح القناة: قيمة مجهولة أو نموذج لم يتحمّل محرّكه يُجهض القناة برمز الشرط المسبق الفاشل وباسم النموذج في الرسالة، وغياب المفتاح يقع على النموذج الافتراضي حفاظاً على العملاء الأقدم (NFR-COMPAT-002[20]).

وتتكامل الأنماط الثلاثة على الرسالتين نفسيهما باختلاف الحقول المأهولة: النصفان يملآن صورتَي النصفين وقناتي الصوت وخريطتي 56×56؛ والكلام يملأ صورة الإطار الكامل المؤطرة وقناة الصوت عالية المعدل وخريطة واحدة خاضعة لبوابة الثقة؛ واللمس يضيف استعلامات PixelQuery داخل القناة (بحد أربعة لكل كتلة) وأعلام التجميد والعناقيد، وتعود خريطة طاقته بدقتها الأصلية 14×14 بأبعاد صريحة. ويحمل كل ردّ صدى معرّف النموذج ورقم تسلسل وحقول توقيت الخادم؛ وعلى هذه الحقول

بُنيت ثلاثة أشياء دفعة واحدة: مرشّح التقادم عند التبديل، وكشفُ الفجوات وإخفاؤها صمماً مكافئ المدة، وقياسُ منظومة الحمل للخادم عبر بروتوكوله ذاته دون أي أدوات حقن داخلية.

أما تكامل بيئة التشغيل فيعبر حدّين موثّقين: حدّ WSL2 بين ويندوز المضيف وأوبونتو حيث يقيم TensorFlow بدعم المسرّع، بإجراء ربط شبكي موثّق (UC-17)؛ وحدّ الشبكة المحلية بين الهاتف والخادم بعنوان مضيف يضبطه المستخدم من التطبيق ويُحفظ عبر التشغيلات (FR-071) ومنفذ ثابت 50051. وقد كُشف أثناء التوثيق تناقضٌ واحد بين تعليقٍ في ملف البروتوكول (يزعم إرجاع صوت الكلام بمعدل 21000 هرتز) وبين السجلّ المرجعي (22050 هرتز)؛ والكود هو الحَكَم، وسُجِّل التناقض للإصلاح ثم أُصلح فعلاً: يعلن الملف اليوم 22050 هرتز على السلك و21000 هرتز داخل المحرّك وحده، ورُصد تطابقُ النسختين بايتياً بمطابقة SHA-256 بتاريخ 13-08-2026 — وهذا نموذج لمنهج التقرير كله: الكود أولاً، والتعليقات تُفترض متقدمة حتى يثبت العكس.

4.3 بسودوكود للخوارزميات المحورية

ثلاث خوارزميات تحمل جوهر التنفيذ. أولاها حلقة الخادم لكل جلسة — انتخاب النافذة فالاستدلال فالخياطة [9][11]:

```
for each StreamChunk received on the session:
    buffer.append(audio_pcm); frame_ring.add(decoded_frames) # audio lossless, frames capped
    while (w = newest frame with a FULL audio window centred on it,
           window start aligned to the 256-sample STFT grid,
           advance since last window >= spec.window_min_advance):
        async with GPU_LOCK: # one lock, all sessions
            tracks, heatmaps, diag = engine.infer(window(w)) # p95: 60 ms (SoP) / 154 ms (speech)
            for side in tracks:
                slice = centre_hop_slice(tracks[side]) # hop-long centre slice
                out[side] = overlap_add(slice, crossfade=raised_cosine_128)
                yield StreamResult(seq, model_id_echo, out, quantize(heatmaps),
                                   timing_fields, is_buffering=False)
            if chunk.is_last: yield flush_overlap_tail(); close(OK)
```

والثانية إجابة الاستعلام اللامي من الذاكرة المختبئة — وهي ما يجعل اللمسة فورية (مئين 95 مقيس: 1.56 ملي ثانية) لأنها لا تشغّل أي شبكة:

```
def synthesise_region(cache, region_weights):          # cache: i_k (32x14x14), s_k
(32x256x256),

    v = max_pool(cache.i_k over cells where region_weights > 0)      # |S|, phase -
9.46 MB/window

    mask_w = sigmoid( sum_k w[k] * v[k] * cache.s_k[k] + b )      # linear synth: 33
params

    mask_lin = inverse_logfreq_warp(mask_w)              # 256x256 -> 512x256, BEFORE
renormalisation

    pair = renormalise(mask_lin, complement)             # region + rest sum to the mixture

    spec = pair * cache.magnitude * exp(1j * cache.phase)

    pcm = istft(spec, length=65536) [centre 2.0 s]; energy = rms(pcm)

    return silence_if_below_threshold(pcm, energy)      # honest-silence rule, FR-036
```

والثالثة سياسة الفقد لكل وسيط في باعث الكتل على الهاتف — صوت بلا فقد وإطارات بإبقاء الأحدث:

```
audio_queue: unbounded FIFO          # a dropped audio block is an audible artefact

frame_slot: size-1 'keep latest' # a dropped frame only ages the visual conditioning

on mic_block(5512 samples @44100): audio_queue.push(fir_decimate(block)) # 121-tap

on camera_frame: if now - last >= profile.throttle:
frame_slot.replace(transform(frame))

emitter loop: chunk = StreamChunk(audio=audio_queue.pop_all(),
                                frames=frame_slot.take_if_any(),
queries=pending[<=4])

    stream.send(chunk)      # suspends (never drops) if the channel back-
pressures audio
```

4.4 خطة الاختبارات ونتائجها

بُنيت خطة التحقق طبقاتٍ ستاً، لكلِّ سؤالها الذي صُمِّمت لُجبيته، وربطت كلَّ متطلبٍ بطريقة تحققه (اختبار، تحليل، تفتيش، عرض) عبر مصفوفة تتبّع كاملة في وثيقة التحليل [31]:

الطبقة	ما تغطيه	أبرز النتائج
اختبارات الوحدة	ال خادم والعميل: منطق العوازل، اختيار النافذة، التراكب والجمع (9 اختبارات)، سلاسل إحداثيات اللمس (18 اختباراً)، السجل وعقد المواصفات	79 نجاحاً / 1 تخطُّ في الجولة الختامية؛ خطأ جمع سابقان شُخصاً سكريتاً يدوياً خطأً pytest جمعه فاستُثني مع تسجيل السبب
تكمّل حتمي (إعادة تشغيل)	منصّة replay تدفع مقطعاً ثابتاً عبر البروتوكول السلكي كاملاً وتُقارن الفصل بمرجع دون بث	بيرسون بين القناتين 0.187 بتّاً مقابل 0.097 دون بث [14] على مقطع غيتار+تشيلو داخل مجال النموذج — متطابق حتى الخانة الرابعة عبر إعادة هيكلة الحلقة (0.1872/0.1871): المسار الصوتي لم يُمسَ رقمياً
الحمل والإجهاد	منظومة loadtest مبنية على أكواد المشروع ذاتها (لا أداة عامة) [28]: سيناريوهات خط أساس وحمل وإجهاد واندفاع	الجداول 2 و5-7؛ كل تشغيل يسجّل آلياً بصمة الكود وملف YAML والعناد ليكون قابلاً لإعادة الإنتاج

الطبقة	ما تغطيه	أبرز النتائج
	وثبات مديد وتبديل وحقق أعطال، بقيادة غير متزامنة تفتح N جلسة حقيقية	
اختبارات الأمن (وضعيًا)	فحص انحصار التعرض: مراقبة وجهات الاتصال أثناء الحمل والنقع	صفر وجهة خارج الشبكة المحلية (SEC-001)؛ والوضعية المعلنة: نص صريح على شبكة LAN موثوقة لدراسة مخبرية — TLS والاستيثاق فجوة منتج مصرح بها (FR-P01) لا سهواً
تحقق النموذج المرسل	منصة T0-T5: تدقيق الترحيل، أوراكن المهمة الذرية، مطابقة التفعيلات، والتحقق المتقاطع للتوضيع	هامش الفحص المتقاطع +0.8248 (نجاح)؛ تكافؤ CPU/GPU المسجل؛ زمن الاستدلال المرجعي وسيطاً (140.3-146.3) 142.6 ms
تحقق تطبيق الهاتف (وحدة)	منطق المرشح والعوازل وتبديل النماذج والنقل وهندسة الإطار والخرائط ونموذج العرض وعقد السلك، على آلة JVM عبر ثماني ثغرات اختبار موثقة، بمنتجات مرجعية مولدة باستقلال عن الكود المختبر (NumPy) وخادم gRPC داخل العملية بالأكواد المولدة نفسها؛ ومسبارا التقاط على العتاد (MI-DEV-002/003) — مصرفان لم يُشغلا	157 اختباراً؛ 154 ناجحة و3 مستثناة بسبب مكتوب. مرشح FIR: انحراف تمرير dB -0.0027 / +0.0114 وإخماد dB -80.45 / -74.53؛ إيقاع فعلي 7.5 إطار/ثانية عبر بوابة 125 ms؛ عيب مجال الرؤية D2 = 224/910 = 24.6%؛ تغطية أسطر مرصودة 23.4% للوحدة كاملة و-48 98% لحزم المنطق؛ عشرة عيوب D-M — ومصفوفه الأجهزة صفر جهاز حتى تاريخه

الجدول 5: طبقات خطة الاختبارات ونتيجة كل طبقة.

نُفذت اختبارات الحمل والإجهاد على البيئة المرجعية E-M (الملحق ب) بخادم واحد لم يُعد تشغيله طوال الحملة والنماذج الثلاثة مقيمة، عبر أربع حملات متتابعة أُصلحت بينها العيوب وأُعيد التحقق؛ وسبقها حملة على البيئة الثانوية E-D خضعت نتائجها لتدقيقٍ عدائيٍّ مستقل وثق حدود صلاحيتها (أبرزها أن «سقف تزامن = 1» المبكر كان أثراً لخادمٍ مُنْهَك لا سعة حقيقية، فُنسخ بقياس E-M).

الجدول 6 يلخص السيناريوهات ونتائجها النهائية:

السيناريو	الشروط	النتيجة
خط الأساس، النصفان	جلسة واحدة	TTFR p95 = 6.42 s؛ انحراف الإيقاع p95 < 1 ms؛ الاستدلال 60/65/321 ms (p95/p99/max)؛ تأخر الحلقة p95 ≈ 2 ms
خط الأساس، الكلام	جلسة واحدة	TTFR p95 = 2.77 s؛ إيقاع 250.0 مث وسيطاً بانحراف p95 = 1.18 ms؛ 4 نتائج/ث؛ الاستدلال p95 = 154 ms
الحمل	جلستان (نصفان)	التزام 2/2؛ زمن الخادم p95 = 81-84 ms، والأقصى 350 ms
الإجهاد — سقف التزامن	تصعيد حتى الكسر	النصفان: (0/3) × n=3 (2/2) · n=2 √ · n=1 حيث p95 = 124 ms ما يزال دون بوابة 140 ms لكن الأقصى 1231 ms — فالركبة ذيلية الطابع لا تشبّع حوسبة (استخدام GPU 32% وسيطاً). السقف = 3. الكلام: السقف = 1 بحكم تعريف الإيقاع
الاندفاعة	4 فتحات دفعة واحدة من السكون	نجاة 4/4؛ أسوأ زمن لبلوغ نافذة التزام 11.8 ث
الثبات المديد	30 دقيقة متصلة	كلام: ميل ذاكرة العملية 0.086 مبي/دقيقة، ونمو GPU +93 MiB متباطئاً؛ نصفان (بلا حفظ تشخيصي): ذاكرة 1.03 مبي/دقيقة (3% فوق الحد، ضجيج مقدّر على ذيل 20 دقيقة — أبقى الحد ولم يُلْتَمِ)
التبديل	100 دورة ↔ sonicsight multisensory تحت التدفق	صدى معرف صحيح 1.000؛ ذاكرة العملية -0.04%؛ GPU +11 MiB — لا تسرب حالة بين الإطارين
حقن الأعطال	7 مدخلات مشوّهة + رسائل متضخمة + وسائط منحلّة + 50 انقطاعاً مفاجئاً	احتواء 7/7 دون مساس الجلسة السليمة؛ رفض عند النقل للمتضخمة؛ سلوك معرف 7/7 للمنحلة (زمن الخادم أثناءها p95 = 84 ms)؛ توازن الفتح/الإغلاق 0 =

الجدول 6: نتائج سيناريوهات الحمل والإجهاد — الحالة النهائية بعد إصلاحات الحملات em2-em4.

وقيسست إقامة الذاكرة الرسومية على مدار الحملة كاملة (سؤال لم يكن مقيساً من قبل وكان أكبر مخاطرة نشر غير مكمّمة): البطاقة GTX 1660 Ti بسعة 6144 مبيي بايت:

المرحلة	مستعمل (مبيي بايت)	حرّ (مبيي بايت)
الخادم دافئاً، النماذج الثلاثة محمّلة، ساكناً	894	5073
بعد خطّي أساس النصفين واللمس	1518	4449
بعد أول جلسة كلام	2040	3927
نهاية الحملة (≈ 3 ساعات، كل السيناريوهات)	2650	3317

الجدول 7: تدرّج ذاكرة GPU عبر الحملة — معيار الملاءمة (بقاء 500 MiB ≥ حرّة في الاستقرار) متحقّق بهامش 3.3 غيبي بايت.

ومن أدوات القياس ما يستحق الذكر منهجياً: قياس تأخر حلقة الأحداث باستمرار، لأنه في خادم asyncio المؤشر المبكر الوحيد على الانهيار الجماعي الذي لا تظهره المتوسطات (وقد بقي م99 عند 2 مث طوال التشغيل، وظهر به أثر تحميل النماذج الواحد عند الإقلاع ≈ 341 ث قبل تقديم الخدمة)؛ والإبلاغ بالمئينات p50/p95/p99 والأقصى لا بالمتوسطات؛ وإعادة استهداف مقياس «زمن الخادم» بعد إصلاح التداخل إلى «زمن الاستدلال» المقيس بإحكام حول التمرير الأمامي، لأن الإجمالي صار يقيس إشغال الخط لا كلفته — وسُجّلت إعادة الاستهداف علناً كغيرها.

وتلت حملة الخادم حملة تحقّق مستقلة على العميل، أُجريت على الفرع test/mobile-suite في 13-14 آب 2026 وفق المنهج نفسه: كُتبت الأهداف في ملف mobile_test_targets.yaml قبل وجود أي قياس، وأعلنت ستّ مصالحاتٍ مؤرّخة (REC-1..REC-6) حين خالف المصدرُ الصياغة الأولى للأهداف — أبرزها فصلُ سعة عازل الارتجاج عن عتبة الملاء الأولى، وتصحيح أبعاد طبقة الخريطة، ونقل FR-033 إلى الخادم. وأدخلت ثماني ثغرات اختبار (seams) موثّقة في SEAMS.md، كلٌ منها بحاقن ذي قيمة افتراضية تُبقي المسار الإنتاجي على حاله حرفياً، ولم يُغيّر أي سلوك إنتاجي ولا تُكشف أي ثابتٍ مقفل كإعداد[36].

وبلغت الحصيلة 157 اختبار وحدة: 154 ناجحة و3 مستثناة بسبب مكتوب. والأرقام التالية مرصودة لا مقدّرة: انحراف نطاق التمرير في مرشّح FIR بلغ 0.0114 dB+ عند 1 kHz لمسار النصفين و -0.0027 dB عند 2 kHz لمسار الكلام، وإخماد النطاق الموقوف -74.53 dB و -80.45 dB على الترتيب — وكلها عتباتٌ أُعلنت بعد أول رصدٍ ثم صمدت؛ واستمرارية حالة المرشّح عبر الكتل مطابقةً بائياً تحت تجزئةٍ عدائية؛ والإيقاع الفعلي عبر بوابة 125 ms هو 7.5 إطار/ثانية عند تسليم 30 إطاراً في الثانية، أي 75 عبوراً في عشر ثوانٍ بساعةٍ صورية مضبوطة — فالرقم 8 في المواصفة مقلوبُ الفترة لا المعدّلُ المسلّم؛ وثُبت عيب مجال الرؤية الرأسي في الوضع الطولي عند 24.6% = 224/910. أما التغطية فقيست 23.4% من

أسطر الوحدة كاملة، و48% إلى 98% لحزم المنطق وحدها، بينما بقيت الأكواد المولدة وسطوح الواجهة عند الصفر بحكم التصميم — ولم يُوضع هدفُ تغطيةٍ قبل القياس، فالرقم رصدٌ لا بوابة [12][17].

وحدود هذه الحملة معلنةٌ كنتائجها. لم يُشغل أي اختبارٍ على عتادٍ فعلي: مصفوفةُ الأجهزة صفرُ جهازٍ حتى تاريخه، رغم أن مسباري الالتقاط مُصَرَّفان وجاهزان، وملف DEVICE_MATRIX.md فارغٌ بالقصد لا بالسهو. وأثرُ سقف الرسالة 16 ميغابايت وسلوكُ ركن الصوت تحت التشبع لم يُقاسا عند مستوى الوحدة، لأن النقل داخل العملية يتخطى التسلسل والتحكم بالتدفق — وقد صُرح بذلك بدل افتراضه. وتعدّر خارج الجهاز تأكيدُ فرضية تراصّ مستويات الصورة (D-M-10) لأن مرّمز Robolectric بديلٌ صوري، فنُقل الفصل فيه إلى المسبار على أول هاتفٍ يُشبك، بمحوّل مرجعي وإعٍ بخطوات المستويات يقارن الإطار نفسه بتحويلين. وبقيت طبقات الحمل والإجهاد والثبات المديد ومصفوفات المحاكيات مؤجلةً بقرارٍ معلّن، مسرودةً في MOBILE_TEST_PLAN.md بما كانت ستغطيه — فالخطة تُصرّح بحدود تغطيتها كما تُصرّح بنتائجها [26][27].

4.5 العيوب المكتشفة ومآلاتها

أُثمن ما تنتجه منظومة قياس صادقة عيوبها المكتشفة. عُثر على خمسة عيوب مرقّمة على الخادم، وعشرة على العميل بعد حملة تحقق تطبيق الهاتف، وجملة عيوب تنفيذ موثقة في حالات المتطلبات، وهذا مآلها النهائي:

المعرّف	العيوب	المآل
D-P5-1	خطوة نوافذ الكلام الفعلية 371.5 ms بدل 250 ms المصمّمة (بخسارة إنتاجية 33%) بسببين متراكبين: تسلسل الاستدلال مع سحب الوارد، وحارسٌ تقدّم لا يبلغه مرشّح الكتلتين	أُصلح وجرى التحقق: تداخلٌ استدلالٍ واحدٍ قيد التنفيذ مع استمرار السحب، وضبط الحارس إلى 4480؛ بعده: إيقاع 250.0 ms وسيطاً بانحراف $p95 = 1.18 \text{ ms}$ وزيادة إنتاجية 50%؛ والثمن المقيس المقبول: عمر الصوت $\approx 100 \text{ ms}$
D-P5-2	ارتباط 0.961 بين قناتي إعادة التشغيل بداً خلافاً حقيقياً في البث	أُعيد تصنيفه بمنهجية: المقطع كان حواراً كلامياً خارج مجال نموذج الآلات، والمسار دون بثٍّ يعيد اللافصل ذاته (0.984)، والمرجع الصلب في الأداة كان لمقطع موسيقي مختلف — قيسَ بعدها بمقطع داخل المجال فنجح (0.187)
D-P5-3	توقفات نادرة 1.2–1.5 ث (~مرة كل 10–12 دقيقة بث) على كلا المضيفين المرجعيين بينما م99 دون 110 مث	مفتوح السبب، محدود الأثر ببواباتٍ مُصالحّةٍ معلنة (أضيف حدٌ $p99 \leq 250 \text{ ms}$ وُرفِع الأقصى إلى 1500 ms)؛ مرشّح للعمل المستقبلي
D-P5-4	الخادم لا يسجل سطر إغلاق القناة فتعدّر قياس توازن الفتح/الإغلاق	أُصلح وجرى التحقق: توازن 0 = على 67 فتحاً بينها 50 انقطاعاً مفاجئاً
D-P5-5	نمو ذاكرة GPU بنحو 34 MiB/min في نفع النصفين المديد (مسار PyTorch تحديداً؛ نفع الكلام كاملاً نما 93 MiB فقط)	مفتوح — العيب المقيس الوحيد المتبقي؛ برّئ المسجل التشخيصي بالقياس؛ ويلزم نفعٌ لا يقلّ عن ساعتين مجهّزٌ بتشخيص ذاكرة torch
—	عيوب تنفيذ موثقة في حالات المتطلبات: استمرار الالتقاط في الخلفية (FR-006)؛ متوسطات EMA مفردة على مستوى العملية (FR-020)؛ سقف دفع الكلام 0.75 s بدل 1.5 s لأن الحد مقوّم بالعينات لا بالنواني (FR-033)؛ ومسار /predict القديم بلا قفل GPU ولا مستدعي له (FR-023)	مسجلة صراحةً في الجدول 1 وفي وثيقة التحليل؛ لم تُصلح على هذا الفرع عمداً حفاظاً على مطابقة القياسات للكوود المقيس

المعرّف	العيب	المال
D-M-1	نُسب سقف دفق الكلام (FR-033) إلى العميل في التوثيق السابق	أعيد تصنيفه — لا وجود لسقفٍ مقوّمٍ بالعينات في شجرة العميل؛ عوّالته مقوّمّة بالمللي ثانية والبايتات ومقيسة بالمعدل (33075 B @ 11025 Hz @ 22050 B @ 66150 B). والثابت الفعلي على الخادم $\text{SAFE_DRAIN_SAMPLES} = \text{int}(\text{AUD_RATE} \times 1.5) = 16537$ مع (grpc_server.py:354) $\text{AUD_RATE} = 11025$ (config.py:14) فعدند 22050 Hz تساوي 0.75 s بالضبط. تفتيشٌ مصدرٍ لا قياس
D-M-2	خيّطُ تفرّيع عازل الارتجاج ينجو من stop() ويُبعث مع start() التالي، فيتنافس خيطان على حلقةٍ واحدة	مفتوح محدود الأثر — مثبّت باختبار توصيف؛ يشترط تعليق الكتابة أطول من مهلة الضمّ 500 ms لحظة الإيقاف ثم إعادة تشغيل، ولم يُرصد على عتاد
D-M-10	imageProxyToBitmap يفترض تراصّ مستويات NV21 ويتجاهل rowStride/pixelStride	مفتوح، أثره مرجّح غير مؤكّد — تعدّر تأكّيده خارج الجهاز (مرمّز Robolectric بديلٌ صوري، فاستثنيت ثلاثة اختبارات بسبب مكتوب)؛ يفصل فيه المسبار MI-DEV-002 على أول جهاز، وقرارُ الإصلاح مؤجّلٌ إلى ما بعده
—	سبعة عيوبٍ أخرى على العميل: ابتلاعُ الإلغاء في مسار الرفع القديم (D-M-3)، وغيابُ تخطيط مصنّف لرموز (D-M-4) gRPC، وإسقاط صامت في المرسّح عند عازل خرج قاصر أو عدد بايتاتٍ فردي (D-M-5)، وحشوٌ أصفر عند التفرّيع الجزئي (D-M-6)، وملفّ رفع فارغ بلا كتل (D-M-7)، وارتدادٌ خريطة مشوّهة إلى (D-M-8) 56×56، واختلافٌ طرقي النظام في معنى مُعرّف نموذجٍ مجهول (D-M-9)	واحدٌ مفتوح وستة مفتوحة محدودة الأثر — كلّ مثبّت باختبارٍ مسمّى أو بسطر مصدر، ولم يصلح أيٌّ منها على فرع القياس

الجدول 8: سجل العيوب — أُبقيت إخفاقات القياس ظاهرة حتى أصلح العيب نفسه، ولم يُلَيّن أي هدف لإخفاء عيب.

5. نتيجة الجدوى وحدود النظام

النتيجة المركزية للدراسة، مصاغَةً من القياسات لا من الانطباعات: أثبت النظام أن فصل المصادر الموجّه بصرياً يعمل حياً من طرف إلى طرف على عتاد استهلاكي — هاتفٌ عاديّ وبطاقة رسومات من فئة 6 غيغابايت تستضيف نموذجين بإطارين مختلفين معاً — بهوامش حوسبية مريحة (الاستدلال يستهلك أقل من نصف ميزانية القفزة، واستخدام GPU وسيطاً نحو الثلث عند السقف). غير أن الكمون الإدراكي الحالي — نحو 3 ثوانٍ لنمط النصفين ونحو 1.4 ثانية لنمط الكلام — تفرضه بنية نافذة التحليل في النموذجين لا هندسة النظام: فالكمون الخوارزمي (نصف نافذة توسيطاً) يبتلع كمون المعالجة بمرتبتي عشرتين، وتسريع الاستدلال إلى الصفر لن يغيّر التجربة المحسوسة تغييراً يُذكر [42][43].

وبمقابلة ذلك بما توثّقه أدبيات السمعيات من تحمّل تأخير معالجة في نطاق عشرات المللي ثوانٍ للمعينات السمعية قبل أن يصير التأخير مُدرَكًا ومزعجًا، تكون المسافة الحالية مرتبتيين إلى ثلاث مراتب عشرية، ويكون العامل الحاكم لعبورها تصميم نماذج فصل ذات نوافذ قصيرة جذرياً أو ذات طابع سبي انسيابي [48][49] — وهي مسألة بحث نماذج لا مسألة هندسة أنظمة. هذا التشخيص الدقيق لموضع العائق هو إسهام الدراسة الأول [39][40][41].

وتُقرأ بقية الحدود على وجهها: مجالا النموذجين ضيقان بحكم بيانات تدريبهما (آلات موسيقية لأحدهما، وكلامٌ داخل/خارج الشاشة للآخر) وأداؤهما خارجها غير مضمون — وقد جسدت حادثة D-P5-2 ذلك عملياً؛ والتوضيح خشن الدقة بطبيعته (شبكة 14×14 وخريطة 7×7) وتصريح الواجهة بذلك بدل ادعاء دقة زائفة؛ وسقف التزامن ثلاث جلسات على البطاقة المرجعية بحكم تسلسل GPU؛ والتحقق على العميل نُفذ عند مستوى الوحدة وحده (القسم 4.4) ولم يُنفذ على عتاد: مصفوفة الأجهزة صفرُ جهازٍ حتى تاريخه، والوصولية الكاملة والظروف الشبكية المضطربة مرحلة لاحقة مخططة لم تُنفذ بعد؛ وقائمة فجوات المنتج (FR-P01..P08) تفصل بوضوح ما يلزم منتجاً حقيقياً ولا تقدّمه دراسة الحالة [1][2]. وثمة أعمالٌ أخرى في فصل الكلام السمي-البصري تعالج المشكلة نفسها بمعماريات مختلفة [45][44]، وتوسيعات لاحقة على نموذج فصل الآلات [47][46]؛ ولم تُستعمل في هذه الدراسة لأن نقطتي التحقق المنشورتين المستعملتين هما ما توفّر ضمن نطاقها.

6. الخاتمة

سَلَّم المشروع ما وعد به بوصفه دراسة حالة: خُطَّ فصلٍ سمعي-بصري حيٍّ متكامل يعمل، ونموذجان مختلفان جذرياً يقيمان خلف آلية اختيار واحدة قابلة للتوسعة (مورست إضافة نموذجٍ عبرها مرتين فعلاً)، ومنظومة قياسٍ كتبت أهدافها قبل أرقامها وقاست 43 هدفاً غير وظيفي فكشفت خمسة عيوب مرقمة كان مآلها الصادق: اثنان أصلحا وأعيد التحقق منهما، وواحد أعيد تصنيفه أثراً قياسياً بعد تقصٍّ منهجي، وواحد حُدَّ أثره ببواباتٍ مُصالحَةٍ معلنة، وواحد بقي مفتوحاً موثقاً، وصيغت نتيجة الجدوى تشخيصاً كمياً دقيقاً لموضع العائق أمام التطبيق المساعد المنشود. والأثر المتروك قابلٌ للبناء عليه: عقدُ تسجيلٍ موثقٍ لإضافة النماذج، ومنصّاتُ تحققٍ حتمية، ووثائقُ تتبّعٍ من المتطلب إلى السطر — وكلّه عامٌ في المستودعات الثلاثة أمام اللجنة الموقّرة.

المراجع

النماذج ومجموعات البيانات

- [1] Zhao, H., Gan, C., Rouditchenko, A., Vondrick, C., McDermott, J., & Torralba, A. (2018). The Sound of Pixels. Proceedings of the European Conference on Computer Vision (ECCV 2018).
- [2] Owens, A., & Efros, A. A. (2018). Audio-Visual Scene Analysis with Self-Supervised Multisensory Features. Proceedings of the European Conference on Computer Vision (ECCV 2018). arXiv:1804.03641.
- [3] Gemmeke, J. F., Ellis, D. P. W., Freedman, D., Jansen, A., Lawrence, W., Moore, R. C., Plakal, M., & Ritter, M. (2017). Audio Set: An ontology and human-labeled dataset for audio events. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP 2017).
- [4] Nagrani, A., Chung, J. S., & Zisserman, A. (2017). VoxCeleb: A large-scale speaker identification dataset. Interspeech 2017.
- [5] Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015).
- [6] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016).
- [7] Yu, F., & Koltun, V. (2016). Multi-scale context aggregation by dilated convolutions. International Conference on Learning Representations (ICLR 2016).
- [8] Zhou, B., Khosla, A., Lapedriza, A., Oliva, A., & Torralba, A. (2016). Learning deep features for discriminative localization. IEEE Conference on Computer Vision and Pattern Recognition (CVPR 2016).

معالجة الإشارة

- [9] Griffin, D., & Lim, J. (1984). Signal estimation from modified short-time Fourier transform. IEEE Transactions on Acoustics, Speech, and Signal Processing, 32(2), 236–243.
- [10] Allen, J. B., & Rabiner, L. R. (1977). A unified approach to short-time Fourier analysis and synthesis. Proceedings of the IEEE, 65(11), 1558–1564.
- [11] Harris, F. J. (1978). On the use of windows for harmonic analysis with the discrete Fourier transform. Proceedings of the IEEE, 66(1), 51–83.
- [12] Crochiere, R. E., & Rabiner, L. R. (1983). Multirate Digital Signal Processing. Prentice-Hall.
- [13] Oppenheim, A. V., & Schaffer, R. W. (2010). Discrete-Time Signal Processing (3rd ed.). Prentice Hall.
- [14] Lloyd, S. P. (1982). Least squares quantization in PCM. IEEE Transactions on Information Theory, 28(2), 129–137.

أطر العمل والبروتوكولات والأدوات

- [15] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*.
- [16] Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., et al. (2016). TensorFlow: A system for large-scale machine learning. *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 2016)*.
- [17] Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., et al. (2020). Array programming with NumPy. *Nature*, 585, 357–362.
- [18] Chetlur, S., Woolley, C., Vandermersch, P., Cohen, J., Tran, J., Catanzaro, B., & Shelhamer, E. (2014). cuDNN: Efficient primitives for deep learning. *arXiv:1410.0759*.
- [19] gRPC — A high performance, open source universal RPC framework. <https://grpc.io>
- [20] Google. Protocol Buffers. <https://protobuf.dev>
- [21] Thomson, M., & Benfield, C. (2022). HTTP/2. RFC 9113, Internet Engineering Task Force.
- [22] ITU-T Recommendation T.81 | ISO/IEC 10918-1. Digital compression and coding of continuous-tone still images (JPEG).
- [23] Android Developers — CameraX, AudioRecord, and AudioTrack API references. <https://developer.android.com>
- [24] Android Developers — Guide to app architecture. <https://developer.android.com/topic/architecture>
- [25] JetBrains. Kotlin coroutines and Flow. <https://kotlinlang.org/docs/coroutines-overview.html>
- [26] Robolectric — Android unit testing framework. <https://robolectric.org>
- [27] JaCoCo — Java Code Coverage Library. <https://www.jacoco.org/jacoco/>
- [28] pytest — Python testing framework. <https://docs.pytest.org>

المعايير والمنهجية

- [29] ISO/IEC 25010. Systems and software engineering — Systems and software Quality Requirements and Evaluation (SQuaRE), product quality model.
- [30] ISO/IEC/IEEE 29148:2018. Systems and software engineering — Life cycle processes — Requirements engineering.
- [31] ISO/IEC/IEEE 29119 (Parts 1–4). Software and systems engineering — Software testing.
- [32] Object Management Group (2017). Unified Modeling Language (UML), Version 2.5.1. OMG Document formal/2017-12-05.
- [33] Jacobson, I., Christerson, M., Jonsson, P., & Övergaard, G. (1992). *Object-Oriented Software Engineering: A Use Case Driven Approach*. Addison-Wesley.
- [34] Cockburn, A. (2000). *Writing Effective Use Cases*. Addison-Wesley.

- [35] Larman, C. (2004). Applying UML and Patterns (3rd ed.). Prentice Hall.
- [36] Feathers, M. C. (2004). Working Effectively with Legacy Code. Prentice Hall.
- [37] Nygard, M. (2011). Documenting architecture decisions.
<https://cognitect.com/blog/2011/11/15/documenting-architecture-decisions>
- [38] Clegg, D., & Barker, R. (1994). Case Method Fast-Track: A RAD Approach. Addison-Wesley.

السمعيات وحدود الكمون

- [39] Stone, M. A., & Moore, B. C. J. (1999). Tolerable hearing aid delays. I. Estimation of limits imposed by the auditory path alone using simulated hearing losses. *Ear and Hearing*, 20(3), 182–192.
- [40] Stone, M. A., & Moore, B. C. J. (2002). Tolerable hearing aid delays. II. Estimation of limits for open canal fittings. *Ear and Hearing*, 23(4), 325–338.
- [41] Agnew, J., & Thornton, J. M. (2000). Just noticeable and objectionable group delays in digital hearing aids. *Journal of the American Academy of Audiology*, 11(6), 330–336.
- [42] Bregman, A. S. (1990). Auditory Scene Analysis: The Perceptual Organization of Sound. MIT Press.
- [43] Cherry, E. C. (1953). Some experiments on the recognition of speech, with one and two ears. *The Journal of the Acoustical Society of America*, 25(5), 975–979.

أعمال ذات صلة

- [44] Ephrat, A., Mosseri, I., Lang, O., Dekel, T., Wilson, K., Hassidim, A., Freeman, W. T., & Rubinstein, M. (2018). Looking to listen at the cocktail party: A speaker-independent audio-visual model for speech separation. *ACM Transactions on Graphics*, 37(4) (SIGGRAPH 2018).
- [45] Afouras, T., Chung, J. S., & Zisserman, A. (2018). The conversation: Deep audio-visual speech enhancement. *Interspeech 2018*.
- [46] Zhao, H., Gan, C., Ma, W.-C., & Torralba, A. (2019). The sound of motions. *IEEE International Conference on Computer Vision (ICCV 2019)*.
- [47] Gao, R., & Grauman, K. (2019). Co-separating sounds of visual objects. *IEEE International Conference on Computer Vision (ICCV 2019)*.
- [48] Luo, Y., & Mesgarani, N. (2019). Conv-TasNet: Surpassing ideal time–frequency magnitude masking for speech separation. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 27(8), 1256–1266.
- [49] Luo, Y., Chen, Z., & Yoshioka, T. (2020). Dual-path RNN: Efficient long sequence modeling for time-domain single-channel speech separation. *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP 2020)*.

الملحق أ — بيئات القياس المرجعية

البيئة	المواصفات	دورها
E-M	WSL2 Ubuntu on Windows 10 Pro 19045 · GTX 1660 Ti 6 GiB (driver 610.88) · Python 3.12.13 · TensorFlow 2.21.0 (GPU) · torch 2.11.0+cu128 · grpcio 1.83.0	بيئة القياس الرئيسية: كل أرقام الجداول 2 و 6 و 7 قيست عليها، بخادم واحد دون إعادة تشغيل والنماذج الثلاثة مقيمة
E-D	Windows Pro (build 26200) · i7-9750H · 16 GiB RAM · GTX 1650 4 GiB (driver 595.97) · Python 3.11.9 · torch 2.6.0+cu124 · NO TensorFlow	بيئة التطوير واختبارات الوحدة، وحملة قياس أولى دُقِّقت حدودُ صلاحيتها؛ وأُثبتت عملياً تحلُّلُ غياب (TensorFlow (FR-024 وأن بطاقة 4 غيبي لا تحمل جلسي نصفين
E-A	جهاز أندرويد (هاتف الفريق) — لم تُثبَّت مصفوفة أجهزة بعد	بيئة العميل على عتاد؛ المسباران مُصرَّفان ولم يُشغَّلَا — صفرُ جهازٍ مقيس، وأهداف المصفوفة مرحلة لاحقة مصرَّح بها
E-U	Windows 11 · Gradle 8.13 · AGP 8.13.2 · JBR 21 · Robolectric 4.16 @ SDK 35	بيئة اختبارات وحدة العميل: كل أرقام حملة تطبيق الهاتف في القسم 4.4 قيست عليها

الجدول 9: البيئات المرجعية — كل رقم في هذا التقرير يشير إلى بيئته.